

Project 1: Safe Mobile Robot Button Navigation (Ομάδα 1)

ΕΜΜΑΝΟΥΉΛ ΠΑΞΙΜΑΔΑΚΗΣ 1100972 & ΔΗΜΗΤΡΙΟΣ ΦΙΛΪΠΠΟΥΛΟΣ 1101130,
Τμήμα ΗΜ&ΤΥ, Πανεπιστήμιο Πατρών, Ελλάδα

CONTENTS

Contents	1
1 Εισαγωγή	1
1.1 Εργαλεία και Βιβλιοθήκες Ανάπτυξης	2
2 Εξοικίωση με Safety Gymnasium	2
3 Δημιουργία Scripted Controller	2
3.1 Αποτελέσματα και Ανάλυση	3
4 Soft Actor Critic	4
4.1 Θεωρητικό Υπόβαθρο	4
4.2 Διαδικασία Εκπαίδευσης και Παράμετροι	4
4.3 Αποτελέσματα	5
5 Safe Proximal Policy Optimization	6
5.1 Θεωρητικό Υπόβαθρο	6
5.2 Υλοποίηση και Παράμετροι Εκπαίδευσης	6
5.3 Μελέτη Αποδόμησης (Ablation Studies)	7
5.4 Αποτελέσματα	7
6 Συμπεράσματα	8
7 Μελλοντικές Επεκτάσεις	8

1 Εισαγωγή

Στο πλαίσιο της παρούσας εργασίας, μελετάται το πρόβλημα της ασφαλούς πλοήγησης ενός αυτόνομου κινητού ρομπότ σε ένα δυναμικό περιβάλλον με εμπόδια. Συγκεκριμένα, καλούμαστε να σχεδιάσουμε και να αξιολογήσουμε έναν ελεγκτή πλοήγησης για ένα αυτόνομο όχημα τύπου Racecar στο περιβάλλον SafetyRacecarButton2-v0 της βιβλιοθήκης Safety Gymnasium. Ο πρωταρχικός στόχος του οχήματος είναι να κινηθεί και να ενεργοποιήσει διαδοχικά τους σωστούς στόχους, ελαχιστοποιώντας ταυτόχρονα την αύξηση του κόστους που προκύπτει από την επαφή με εμπόδια (hazards) και κινούμενους εχθρούς (gremlins).

Για την επίλυση του προβλήματος και την επαλήθευση των αποτελεσμάτων, αναπτύχθηκαν και συγκρίθηκαν τρεις διαφορετικές προσεγγίσεις:

- (1) **Scripted Controller:** Ένας Rule-Based ελεγκτής, ο οποίος λαμβάνει αποφάσεις πλοήγησης και αποφυγής εμποδίων αναλύοντας απευθείας τις μετρήσεις των αισθητήρων Lidar του οχήματος.
- (2) **Soft Actor-Critic:** Μια προσέγγιση Ενισχυτικής Μάθησης η οποία βελτιστοποιεί αποκλειστικά την ανταμοιβή του στόχου, αγνοώντας τους περιορισμούς ασφαλείας (Reward-only Baseline).

- (3) **PPO**: Μια ασφαλής προσέγγιση Ενισχυτικής Μάθησης η οποία χρησιμοποιεί πολλαπλασιαστές Lagrange για να εξισορροπήσει δυναμικά τη μεγιστοποίηση της ανταμοιβής με την τήρηση των περιορισμών ασφαλείας.

1.1 Εργαλεία και Βιβλιοθήκες Ανάπτυξης

Για την υλοποίηση και την πειραματική αξιολόγηση του συστήματος χρησιμοποιήθηκε ένα σύγχρονο οικοσύστημα λογισμικού, το οποίο εξασφαλίζει τη φορητότητα και την επαναληψιμότητα των πειραμάτων:

- **Python 3.11**: Η βασική γλώσσα προγραμματισμού που χρησιμοποιήθηκε.
- **Virtual Environment**: Χρησιμοποιήθηκε για την απομόνωση των εξαρτήσεων κατά την τοπική ανάπτυξη και την αποφυγή συγκρούσεων μεταξύ των εκδόσεων των πακέτων (μόνο σε αρχικά στάδια του πρότζεκτ για την εύρεση σωστής έκδοσης Python και βιβλιοθηκών).
- **Docker**: Όλη η διαδικασία εκπαίδευσης και αξιολόγησης ενσωματώθηκε σε containers, επιτρέποντας την εκτέλεση του κώδικα σε οποιοδήποτε περιβάλλον χωρίς την ύπαρξη conflicts.
- **Safety Gymnasium**: Το περιβάλλον προσομοίωσης για την υλοποίηση της εργασίας.
- **PyTorch & Stable-Baselines3 (SB3)**: Η βιβλιοθήκη βαθιάς μάθησης και το framework ενισχυτικής μάθησης που χρησιμοποιήθηκαν για την εκπαίδευση των μοντέλων.
- **TensorBoard**: Εργαλείο οπτικοποίησης των μετρικών των μοντέλων.

2 Εξοικίωση με Safety Gymnasium

Το περιβάλλον SafetyRacerButton2-v0 προσφέρει μια μοναδική πρόκληση πλοήγησης. Το ρομπότ είναι ένα Racer, το οποίο ελέγχεται μέσω ενός χώρου ενεργειών: $u = [v, \theta]^T$, όπου v είναι η επιθυμητή ταχύτητα των πίσω τροχών και θ είναι η γωνία διεύθυνσης των μπροστινών τροχών.

Η ανατροφοδότηση που λαμβάνει ο agent από το περιβάλλον σε κάθε χρονικό βήμα αποτελείται από μια εξάδα τιμών: (observation, reward, cost, terminated, truncated, info).

Ο χώρος παρατηρήσεων (observation space) περιλαμβάνει μετρήσεις από διάφορους αισθητήρες, όπως:

- **Accelerometer, Velocimeter, Gyro, Magnetometer**: Αισθητήρες που καταγράφουν την εσωτερική κατάσταση του οχήματος.
- **Lidar Sensors (Goal, Buttons, Hazards, Gremlins)**: Ψευδο-Lidar αισθητήρες 16 κατευθύνσεων (ένας (1) αισθητήρας (ήρας) για κάθε (άθε) αντικείμενο (είμενο)). Κάθε αισθητήρας επιστρέφει μια τιμή που υποδηλώνει την απόσταση του αντίστοιχου αντικειμένου σε μια συγκεκριμένη κατεύθυνση.

Για τη σταθεροποίηση και τη βελτίωση της εκπαίδευσης των νευρωνικών δικτύων, εφαρμόστηκαν κατάλληλοι μετασχηματιστές στο περιβάλλον, όπως για την κανονικοποίηση των παρατηρήσεων, την εξομάλυνση των ενεργειών του αυτοκινήτου για την αποφυγή απότομων αλλαγών πορείας, και το frame stacking για την αντίληψη της χρονικής εξέλιξης της κίνησης.

3 Δημιουργία Scripted Controller

Για τη δημιουργία ενός baseline και για την κατανόηση της δυναμικής του περιβάλλον, σχεδιάστηκε και υλοποιήθηκε ένας Scripted Controller. Η λογική του ελεγκτή βασίζεται στην ανάλυση των σημάτων Lidar και χωρίζεται στα εξής στάδια:

- (1) **Ανίχνευση Στόχου**: Ο agent εντοπίζει την κατεύθυνση του επιθυμητού κουμπιού βρίσκοντας το μέγιστο σήμα στον αισθητήρα goal_lidar.
- (2) **Διαχωρισμός Εμποδίων**: Για την αποφυγή συγκρούσεων, ο ελεγκτής συνδυάζει τις μετρήσεις των αισθητήρων hazards_lidar, gremlins_lidar και των λανθασμένων

- κουμπιών (buttons_lidar εξαιρώντας την κατεύθυνση του τρέχοντος στόχου) σε έναν ενιαίο χάρτη εμποδίων.
- (3) **Επιλογή Κατεύθυνσης Κίνησης (Gear Selection):** Αν ο στόχος βρίσκεται πίσω από το όχημα, το όχημα κατευθύνεται προς τα πίσω, ενώ στην αντίθετη περίπτωση μπροστά.
 - (4) **Αποφυγή Εμποδίων:** Η ανίχνευση εμποδίων γίνεται στις 2 κατευθύνσεις κίνησης. Αν ανιχνευθεί εμπόδιο σε απόσταση μικρότερη από ένα όριο ασφαλείας στην κατεύθυνση κίνησης, ο agent στρίβει κατάλληλα μακριά από το εμπόδιο (επιλέγοντας την πλευρά με το μικρότερο κόστος εμποδίων), ενώ παράλληλα μειώνει την ταχύτητά του.

3.1 Αποτελέσματα και Ανάλυση

Ο σχεδιασμένος Scripted Controller αξιολογήθηκε στο περιβάλλον SafetyRacecarButton2-v0 για 20 ανεξάρτητα επεισόδια με διαφορετικούς τυχαίους σπόρους. Κάθε επεισόδιο είχε μέγιστη διάρκεια 1000 βήματα. Τα συγκεντρωτικά αποτελέσματα της αξιολόγησης παρουσιάζονται στον Πίνακα 1.

Table 1. Αποτελέσματα Αξιολόγησης του Scripted Controller (20 επεισόδια)

Μετρική	Τιμή / Επίδοση
Αριθμός Επεισοδίων	20
Μέση Ανταμοιβή (Mean Reward)	+3.1368 ± 2.5198
Ελάχιστη / Μέγιστη Ανταμοιβή	[+0.1886, +9.0047]
Μέσο Κόστος Ασφάλειας (Mean Cost)	202.80 ± 251.51
Μέγιστο Κόστος Επεισοδίου (Max Cost)	819.00
Ποσοστό Επεισοδίων με Μηδενικό Κόστος (Zero-Cost Rate)	10.0% (2/20)
Ποσοστό Ασφαλών Επεισοδίων (Safe Episode Rate, $Cost \leq 25.0$)	30.0% (6/20)
Μέσο Μήκος Επεισοδίου (Mean Episode Length)	1000.0 βήματα
Συνδυασμένο Σκορ (Combined Score, $R - 1.0 \times C$)	-199.6632

3.1.1 *Ανάλυση Συμπεριφοράς και Περιορισμών.* Από την ανάλυση των αποτελεσμάτων και την παρατήρηση της κίνησης του οχήματος, προκύπτουν τα ακόλουθα συμπεράσματα για τη συμπεριφορά του ελεγκτή:

- **Ικανότητα Πλοήγησης:** Ο ελεγκτής επιτυγχάνει θετική μέση ανταμοιβή (+3.1368), γεγονός που δείχνει ότι το όχημα καταφέρνει να εντοπίσει και να ενεργοποιήσει τους επιθυμητούς στόχους (buttons). Σε ορισμένα επεισόδια (π.χ. seed 11), η ανταμοιβή φτάνει έως και +9.0047, υποδηλώνοντας επιτυχή και γρήγορη πλοήγηση όταν η διάταξη των εμποδίων είναι ευνοϊκή.
- **Ζητήματα Ασφάλειας:** Το μέσο κόστος ασφαλείας είναι εξαιρετικά υψηλό (202.80), υπερβαίνοντας κατά πολύ το επιθυμητό όριο των 25.0. Το ποσοστό των ασφαλών επεισοδίων είναι μόλις 30.0%, ενώ σε ορισμένες περιπτώσεις (π.χ. seed 9 και seed 16), το συσσωρευμένο κόστος αγγίζει πολύ υψηλές τιμές (819.0 και 746.0 αντίστοιχα).
- **Ανάλυση Αποτυχιών (Collisions):** Οι κύριες αιτίες για το υψηλό κόστος και τις συγκρούσεις είναι:
 - (1) **Έλλειψη Δυναμικής Πρόβλεψης:** Ο ελεγκτής λαμβάνει αποφάσεις αντιδραστικά (reactive control) με βάση τις τρέχουσες μετρήσεις Lidar. Λόγω της αδράνειας του Racecar, όταν το όχημα κινείται με μεγάλη ταχύτητα, η απόσταση φρεναρίσματος και στροφής είναι μεγαλύτερη από το όριο ανίχνευσης των εμποδίων, με αποτέλεσμα να προσκρούει σε αυτά προτού προλάβει να ανακόψει ταχύτητα.

- (2) **Παγίδευση σε Τοπικά Ελάχιστα (Stuck States):** Σε περιοχές με υψηλή πυκνότητα εμποδίων ή κοντά σε κινούμενους εχθρούς (gremlins), ο ελεγκτής μπορεί να παρουσιάσει ταλαντώσεις στην κατεύθυνση τιμονιού, με αποτέλεσμα να παγιδεύεται και να συγκρούεται επανειλημμένα με το ίδιο εμπόδιο, συσσωρεύοντας τεράστιο κόστος εντός των 1000 βημάτων του επεισοδίου.
- (3) **Τυφλά Σημεία Αισθητήρων:** Αν και οι Lidar αισθητήρες καλύπτουν 16 κατευθύνσεις, η απλοποιημένη λογική αποφυγής ενδέχεται να μην υπολογίζει σωστά το πλάτος του οχήματος κατά τη διάρκεια κλειστών στροφών, οδηγώντας σε πλευρικές επαφές με τα εμπόδια.
- **Σταθερότητα Μήκους Επεισοδίου:** Το γεγονός ότι όλα τα επεισόδια διαρκούν ακριβώς 1000 βήματα δείχνει ότι το όχημα δεν οδηγείται σε πρόωρο τερματισμό (terminated), αλλά συνεχίζει να λειτουργεί καθ' όλη τη διάρκεια του προσομοιωμένου χρόνου, προσπαθώντας συνεχώς να προσεγγίσει τους στόχους.

4 Soft Actor Critic

Η πρώτη προσέγγιση Ενισχυτικής Μάθησης που αναπτύχθηκε βασίζεται στον αλγόριθμο **Soft Actor-Critic (SAC)**. Ο SAC είναι ένας off-policy αλγόριθμος τύπου actor-critic που λειτουργεί σε συνεχή χώρο ενεργειών και βασίζεται στο πλαίσιο της *Μεγιστοποίησης της Εντροπίας (Maximum Entropy Reinforcement Learning)*.

4.1 Θεωρητικό Υπόβαθρο

Σε αντίθεση με τα κλασικά μοντέλα ενισχυτικής μάθησης που μεγιστοποιούν αποκλειστικά το άθροισμα των αναμενόμενων ανταμοιβών, ο SAC εισάγει έναν όρο εντροπίας στη συνάρτηση στόχου. Ο στόχος του ελεγκτή είναι να μεγιστοποιήσει τόσο την αναμενόμενη ανταμοιβή όσο και την εντροπία της πολιτικής του:

$$J(\pi) = \sum_{t=0}^T \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t))] \quad (1)$$

όπου $\mathcal{H}(\pi(\cdot|s_t)) = -\mathbb{E}_{a \sim \pi} [\log \pi(a|s_t)]$ είναι η εντροπία της πολιτικής, η οποία μετρά την τυχαιότητα ή την ποικιλομορφία των επιλεγόμενων ενεργειών, και α είναι η παράμετρος θερμοκρασίας (temperature parameter) που καθορίζει τη σχετική σημασία του όρου της εντροπίας έναντι της ανταμοιβής. Η μεγιστοποίηση της εντροπίας ενθαρρύνει την ενεργή εξερεύνηση του χώρου καταστάσεων, αποτρέπει την πρόωρη σύγκλιση της πολιτικής σε τοπικά ελάχιστα και επιτρέπει στο όχημα να ανακαλύπτει εναλλακτικές τροχιές κίνησης.

Στην εργασία αυτή, ο SAC χρησιμοποιείται ως **Reward-only Baseline**. Αυτό σημαίνει ότι ο πράκτορας εκπαιδεύεται με μοναδικό στόχο τη μεγιστοποίηση της ανταμοιβής πλοήγησης (ενεργοποίηση των σωστών κουμπιών), αγνοώντας πλήρως το κόστος ασφάλειας (cost) που προκύπτει από τις συγκρούσεις με εμπόδια (hazards) ή gremlins. Η προσέγγιση αυτή μας επιτρέπει να προσδιορίσουμε το άνω όριο της επίδοσης (ανταμοιβής) που μπορεί να επιτευχθεί στο συγκεκριμένο περιβάλλον, καθώς και το κόστος ασφάλειας που προκύπτει όταν δεν επιβάλλονται περιορισμοί.

4.2 Διαδικασία Εκπαίδευσης και Παράμετροι

Η εκπαίδευση του SAC πραγματοποιήθηκε με χρήση της βιβλιοθήκης Stable-Baselines3 (SB3). Για τη βελτιστοποίηση της μάθησης και τη σταθεροποίηση του νευρωνικού δικτύου, εφαρμόστηκε η ακόλουθη διαδικασία:

- **Κανονικοποίηση Παρατηρήσεων (Observation Normalization):** Χρησιμοποιήθηκε ο wrapper ObsNormWrapper ο οποίος υπολογίζει online τον τρέχοντα μέσο όρο και την τυπική απόκλιση των παρατηρήσεων (μέθοδος Welford) και τις κανονικοποιεί στο διάστημα $[-10, 10]$. Αυτό αποτρέπει τον κορεσμό των ενεργοποιήσεων του δικτύου λόγω των μεγάλων διακυμάνσεων των αισθητήρων Lidar.
- **Εξομάλυνση Ενεργειών (Action Smoothing):** Εφαρμόστηκε ο wrapper ActionSmoothingWrapper με εκθετικό κινητό μέσο όρο (EMA) και συντελεστή $\alpha = 0.8$. Αυτό βοηθά στη μείωση των απότομων αλλαγών στην ταχύτητα και τη γωνία διεύθυνσης, προστατεύοντας το όχημα από ανεξέλεγκτες ολισθήσεις.
- **Αρχιτεκτονική Δικτύου:** Χρησιμοποιήθηκε ένα Multi-Layer Perceptron (MLP) με δύο κρυφά επίπεδα των 256 νευρώνων το καθένα για τον actor και τον critic.

Οι βασικές υπερπαραμέτροι (hyperparameters) της εκπαίδευσης παρουσιάζονται στον Πίνακα 2.

Table 2. Υπερπαραμέτροι Εκπαίδευσης του SAC

Υπερπαραμέτρος	Τιμή
Συνολικά Βήματα Εκπαίδευσης (Total Timesteps)	3.000.000
Ρυθμός Μάθησης (Learning Rate)	3×10^{-4}
Μέγεθος Replay Buffer (Buffer Size)	200.000
Μέγεθος Batch (Batch Size)	256
Βήματα Προθέρμανσης (Learning Starts)	5.000
Συντελεστής Έκπτωσης (γ)	0.99
Συντελεστής Ενημέρωσης Στόχου (τ)	0.005
Συχνότητα Εκπαίδευσης (Train Frequency)	1 step
Βήματα Κλίσης ανά Βήμα Περιβάλλοντος (Gradient Steps)	1

4.3 Αποτελέσματα

Τα αποτελέσματα της αξιολόγησης του εκπαιδευμένου SAC μοντέλου για 20 επεισόδια παρουσιάζονται στον Πίνακα 3 (τα δεδομένα θα συμπληρωθούν μετά την ολοκλήρωση της εκπαίδευσης).

Table 3. Αποτελέσματα Αξιολόγησης του SAC Controller

Μετρική	Τιμή / Επίδοση
Αριθμός Επεισοδίων	20
Μέση Ανταμοιβή (Mean Reward)	[Υπό Εκπαίδευση]
Ελάχιστη / Μέγιστη Ανταμοιβή	[Υπό Εκπαίδευση]
Μέσο Κόστος Ασφάλειας (Mean Cost)	[Υπό Εκπαίδευση]
Μέγιστο Κόστος Επεισοδίου (Max Cost)	[Υπό Εκπαίδευση]
Ποσοστό Επεισοδίων με Μηδενικό Κόστος	[Υπό Εκπαίδευση]
Ποσοστό Ασφαλών Επεισοδίων ($Cost \leq 25.0$)	[Υπό Εκπαίδευση]
Μέσο Μήκος Επεισοδίου	[Υπό Εκπαίδευση]
Συνδυασμένο Σκορ ($R - 1.0 \times C$)	[Υπό Εκπαίδευση]

5 Safe Proximal Policy Optimization

Για την επίλυση του προβλήματος της ασφάλειας, σχεδιάστηκε και υλοποιήθηκε μια προσέγγιση **Constrained Reinforcement Learning** βασισμένη στον αλγόριθμο Proximal Policy Optimization με χρήση πολλαπλασιαστών Lagrange (**PPO-Lagrangian**).

5.1 Θεωρητικό Υπόβαθρο

Το πρόβλημα της ασφαλούς πλοήγησης μοντελοποιείται ως ένα *Περιορισμένο Μαρκοβιανό Πρόγραμμα Αποφάσεων* (Constrained Markov Decision Process - CMDP). Στόχος είναι η εύρεση μιας πολιτικής π που μεγιστοποιεί την αναμενόμενη ανταμοιβή, ενώ ταυτόχρονα διασφαλίζει ότι το αναμενόμενο κόστος ασφάλειας δεν υπερβαίνει ένα όριο C_{limit} :

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t r_t \right] \quad \text{subject to} \quad \mathbb{E} \left[\sum_{t=0}^T \gamma^t c_t \right] \leq C_{\text{limit}} \quad (2)$$

Η μέθοδος των πολλαπλασιαστών Lagrange επιτρέπει τη μετατροπή του περιορισμένου αυτού προβλήματος σε ένα ισοδύναμο μη περιορισμένο πρόβλημα βελτιστοποίησης, εισάγοντας έναν θετικό πολλαπλασιαστή $\beta \geq 0$:

$$\max_{\pi} \min_{\beta \geq 0} \mathcal{L}(\pi, \beta) = J_R(\pi) - \beta(J_C(\pi) - C_{\text{limit}}) \quad (3)$$

όπου $J_R(\pi)$ είναι η αναμενόμενη ανταμοιβή και $J_C(\pi)$ είναι το αναμενόμενο κόστος. Η βελτιστοποίηση πραγματοποιείται σε δύο επίπεδα:

- (1) **Βελτιστοποίηση Πολιτικής (π):** Η πολιτική εκπαιδεύεται να μεγιστοποιεί τη διαμορφωμένη συνάρτηση στόχου (Lagrangian reward): $r_{\text{shaped}} = r - \beta \cdot c$. Αν ο πολλαπλασιαστής β είναι μεγάλος, ο πράκτορας τιμωρείται αυστηρά για κάθε σύγκρουση, στρέφοντας την προσοχή του στην ασφάλεια. Αν $\beta = 0$, ο πράκτορας συμπεριφέρεται όπως ένας κλασικός ελεύθερος περιορισμών πράκτορας.
- (2) **Ενημέρωση Πολλαπλασιαστή (β):** Ο πολλαπλασιαστής ενημερώνεται δυναμικά στο τέλος κάθε rollout μέσω gradient ascent:

$$\beta \leftarrow \max(0, \beta + \eta(J_C(\pi) - C_{\text{limit}})) \quad (4)$$

όπου η είναι ο ρυθμός μάθησης της παραμέτρου Lagrange (Lagrangian learning rate). Αν το μέσο κόστος του rollout υπερβαίνει το C_{limit} , το β αυξάνεται, εντείνοντας την ποινή ασφάλειας. Αν το κόστος είναι χαμηλότερο από το όριο, το β μειώνεται, επιτρέποντας στον πράκτορα να εστιάσει ξανά στη συλλογή ανταμοιβών.

5.2 Υλοποίηση και Παράμετροι Εκπαίδευσης

Η υλοποίηση βασίζεται στη βιβλιοθήκη Stable-Baselines3 με την προσθήκη custom wrappers και callbacks στο αρχείο `train_ppo_lagrangian.py`:

- **LagrangianWrapper:** Αυτός ο custom wrapper παρεμβάλλεται στο βήμα της προσομοίωσης και τροποποιεί την ανταμοιβή που επιστρέφει το περιβάλλον σε $r_{\text{shaped}} = r - \beta \cdot c$, χρησιμοποιώντας την τρέχουσα τιμή του β από τον callback.
- **SafetyToGymnasiumWrapper:** Προσαρμόζει το 6-tuple του Safety Gymnasium στο 5-tuple που αναμένει η SB3. Επιπλέον, εισάγει έναν μηχανισμό ασφαλείας: αν το συσσωρευμένο κόστος του επεισοδίου υπερβεί την τιμή 50.0, το επεισόδιο τερματίζεται πρόωρα (`terminated = True`) και επιβάλλεται μια σταθερή ποινή ανταμοιβής -5.0 , αποτρέποντας τον πράκτορα από το να συνεχίσει να συγκρούεται.

- **LagrangianCallback:** Παρακολουθεί το μέσο κόστος των επεισοδίων σε κάθε rollout και ενημερώνει δυναμικά την τιμή του β σύμφωνα με τον κανόνα ενημέρωσης, καταγράφοντας την εξέλιξή του στο TensorBoard.
- **StatsSyncEvalCallback:** Διασφαλίζει ότι οι online στατιστικές κανονικοποίησης (mean/std) του εκπαιδευόμενου wrapper μεταφέρονται αυτούσιες στο περιβάλλον αξιολόγησης (evaluation environment) κατά τη διάρκεια των ενδιάμεσων ελέγχων, ώστε να μην διαταράσσεται η συμπεριφορά του ελεγκτή.

Οι βασικές υπερπαράμετροι εκπαίδευσης του PPO-Lagrangian παρουσιάζονται στον Πίνακα 4.

Table 4. Υπερπαράμετροι Εκπαίδευσης του PPO-Lagrangian

Υπερπαράμετρος	Τιμή
Συνολικά Βήματα Εκπαίδευσης	3.000.000
Ρυθμός Μάθησης (α)	3×10^{-4}
Μέγεθος Batch (Batch Size)	64
Μήκος Rollout (N Steps)	2048
Αριθμός Epochs (N Epochs)	10
Συντελεστής Έκπτωσης (γ)	0.99
Όριο Κόστους (C_{limit})	25.0
Ρυθμός Μάθησης Lagrange (η)	0.02
Μέγιστη Τιμή Πολλαπλασιαστική (β_{max})	10.0
Συντελεστής Εντροπίας (Entropy Coefficient)	0.0

5.3 Ανάλυση Επιμέρους Στοιχείων (Ablation Studies)

Στο πλαίσιο του σχεδιασμού του συστήματος ελέγχου, ενσωματώθηκαν κατάλληλοι μετασχηματιστές (wrappers) για τη βελτίωση της εκπαίδευσης και της σταθερότητας του πράκτορα. Συγκεκριμένα:

- **Action Smoothing (Εξομάλυνση Ενεργειών):** Όπως αναφέρθηκε στην Ενότητα 4, χρησιμοποιήθηκε για τη μείωση της ολίσθησης και τη βελτίωση της σταθερότητας του οχήματος.
- **Observation Normalization (Κανονικοποίηση Παρατηρήσεων):** Όπως περιγράφηκε στην Ενότητα 4, εφαρμόστηκε κανονικοποίηση για την αποφυγή κορεσμού των νευρώνων.
- **Frame Stacking (Στοιβάξη Πλαισίων):** Εισήχθη στοιβάξη διαδοχικών παρατηρήσεων (frame stack), η οποία επιτρέπει στον πράκτορα να αντιλαμβάνεται τη σχετική ταχύτητα και την κατεύθυνση κίνησης των δυναμικών εμποδίων (gremlins), παρέχοντας την απαραίτητη χρονική πληροφορία που απουσιάζει από μια μεμονωμένη παρατήρηση.

5.4 Αποτελέσματα

Τα αποτελέσματα της αξιολόγησης του εκπαιδευμένου PPO-Lagrangian μοντέλου για 20 επεισόδια παρουσιάζονται στον Πίνακα 5 (τα δεδομένα θα συμπληρωθούν μετά την ολοκλήρωση της εκπαίδευσης).

Table 5. Αποτελέσματα Αξιολόγησης του PPO-Lagrangian Controller

Μετρική	Τιμή / Επίδοση
Αριθμός Επεισοδίων	20
Μέση Ανταμοιβή (Mean Reward)	[Υπό Εκπαίδευση]
Ελάχιστη / Μέγιστη Ανταμοιβή	[Υπό Εκπαίδευση]
Μέσο Κόστος Ασφάλειας (Mean Cost)	[Υπό Εκπαίδευση]
Μέγιστο Κόστος Επεισοδίου (Max Cost)	[Υπό Εκπαίδευση]
Ποσοστό Επεισοδίων με Μηδενικό Κόστος	[Υπό Εκπαίδευση]
Ποσοστό Ασφαλών Επεισοδίων ($Cost \leq 25.0$)	[Υπό Εκπαίδευση]
Μέσο Μήκος Επεισοδίου	[Υπό Εκπαίδευση]
Συνδυασμένο Σκορ ($R - 1.0 \times C$)	[Υπό Εκπαίδευση]

6 Συμπεράσματα

Στο πλαίσιο της παρούσας εργασίας μελετήθηκαν και αναλύθηκαν τρεις διαφορετικοί ελεγκτές για το πρόβλημα της ασφαλούς πλοήγησης ενός Racacar στο δυναμικό περιβάλλον SafetyRacacarButton2-v0 του Safety Gymnasium.

Ο **Scripted Controller** αποτελεί μια απλή και άμεση rule-based προσέγγιση, η οποία βασίζεται αποκλειστικά σε Lidar μετρήσεις. Παρόλο που καταφέρνει να πλοηγηθεί και να ενεργοποιήσει κουμπιά (μέση ανταμοιβή +3.1368), η αντιδραστική (reactive) φύση του στερείται της ικανότητας πρόβλεψης των δυναμικών του οχήματος (αδράνεια, ταχύτητα) και των κινούμενων εμποδίων, οδηγώντας σε απαράδεκτα υψηλό μέσο κόστος (202.80) και πολύ χαμηλό ποσοστό ασφαλών επεισοδίων (30%).

Οι δύο προσεγγίσεις Ενισχυτικής Μάθησης (Reinforcement Learning) αναμένεται να προσφέρουν σημαντικές βελτιώσεις:

- Ο **SAC (Reward-only Baseline)** αναμένεται να επιτύχει τη μέγιστη δυνατή ανταμοιβή στο περιβάλλον, καθώς εκπαιδεύεται να βελτιστοποιεί άμεσα την τροχιά του οχήματος προς τους στόχους. Ωστόσο, επειδή αγνοεί πλήρως τους περιορισμούς ασφάλειας, αναμένεται να παρουσιάσει εξαιρετικά υψηλό κόστος ασφάλειας, επιβεβαιώνοντας ότι η κλασική RL δεν επαρκεί για εφαρμογές όπου η ασφάλεια είναι κρίσιμη.
- Ο **PPO-Lagrangian** αποτελεί τη βέλτιστη θεωρητικά λύση, καθώς χρησιμοποιεί δυναμικούς πολλαπλασιαστές Lagrange για να εξισορροπήσει τη μάθηση. Εκπαιδεύεται να τιμωρεί τη συμπεριφορά του πράκτορα όταν το συσσωρευμένο κόστος υπερβαίνει το $C_{\text{limit}} = 25.0$. Αναμένεται να επιτύχει μια ισορροπημένη συμπεριφορά πλοήγησης, διατηρώντας το μέσο κόστος εντός των ασφαλών ορίων και ικανοποιώντας τους περιορισμούς ασφάλειας.

7 Μελλοντικές Επεκτάσεις

Ως μελλοντικές κατευθύνσεις για την περαιτέρω βελτίωση του συστήματος προτείνονται:

- (1) **Ολοκλήρωση και Σύγκριση της Εκπαίδευσης:** Η πλήρης εκπαίδευση των μοντέλων SAC και PPO-Lagrangian για 3.000.000 βήματα και η ποσοτική σύγκριση των αποτελεσμάτων τους με τον Scripted Controller στον τελικό πίνακα αξιολόγησης.
- (2) **Χρήση Εναλλακτικών Αλγορίθμων Safe RL:** Δοκιμή άλλων μεθόδων Constrained RL, όπως ο Constrained Policy Optimization (CPO) ή ο PPO με PID-Lagrangian ελεγκτή, οι οποίοι προσφέρουν πιο ομαλή και σταθερή σύγκλιση της παραμέτρου Lagrange β .

- (3) **Ενσωμάτωση Recurrent Αρχιτεκτονικών:** Χρήση Recurrent Νευρωνικών Δικτύων (π.χ. LSTM/GRU) για την πολιτική, ώστε ο πράκτορας να μπορεί να επεξεργάζεται χρονικές αλληλουχίες παρατηρήσεων. Αυτό θα επιτρέψει την καλύτερη εκτίμηση της ταχύτητας των κινούμενων gremlins χωρίς την ανάγκη μεγάλου frame stacking.
- (4) **Ρύθμιση Συντελεστή Εξομάλυνσης Ενεργειών:** Πειραματισμός με διαφορετικές τιμές του α στον EMA του τιμονιού για την εύρεση της χρυσής τομής μεταξύ της ευελιξίας του οχήματος και της αποφυγής ανεξέλεγκτης ολίσθησης.