

Project 1: Safe Mobile Robot Button Navigation (Ομάδα 1)

ΕΜΜΑΝΟΥΉΛ ΠΑΞΙΜΑΔΑΚΗΣ 1100972 & ΔΗΜΗΤΡΙΟΣ ΦΙΛΩΠΟΥΛΟΣ 1101130,
Τμήμα ΗΜ&ΤΥ, Πανεπιστήμιο Πατρών, Ελλάδα

CONTENTS

Contents	1
1 Εισαγωγή	1
1.1 Εργαλεία και Βιβλιοθήκες Ανάπτυξης	2
2 Εξοικίωση με Safety Gymnasium	2
3 Δημιουργία Scripted Controller	2
3.1 Αποτελέσματα και Ανάλυση	3
4 Simple PPO (Reward-only Baseline)	3
4.1 Θεωρητικό Υπόβαθρο	4
4.2 Διαδικασία Εκπαίδευσης και Παράμετροι	4
4.3 Αποτελέσματα	5
5 Safe Proximal Policy Optimization	5
5.1 Θεωρητικό Υπόβαθρο	5
5.2 Υλοποίηση και Παράμετροι Εκπαίδευσης	6
5.3 Ανάλυση Επιμέρους Στοιχείων (Ablation Studies)	7
5.4 Αποτελέσματα	7
6 Συμπεράσματα	8
7 Μελλοντικές Επεκτάσεις	8

1 Εισαγωγή

Στο πλαίσιο της παρούσας εργασίας, μελετάται το πρόβλημα της ασφαλούς πλοήγησης ενός αυτόνομου κινητού ρομπότ σε ένα δυναμικό περιβάλλον με εμπόδια. Συγκεκριμένα, καλούμαστε να σχεδιάσουμε και να αξιολογήσουμε έναν ελεγκτή πλοήγησης για ένα αυτόνομο όχημα τύπου Racecar στο περιβάλλον SafetyRacecarButton2-v0 της βιβλιοθήκης Safety Gymnasium. Ο πρωταρχικός στόχος του οχήματος είναι να κινηθεί και να ενεργοποιήσει διαδοχικά τους σωστούς στόχους, ελαχιστοποιώντας ταυτόχρονα την αύξηση του κόστους που προκύπτει από την επαφή με εμπόδια (hazards) και κινούμενους εχθρούς (gremlins).

Για την επίλυση του προβλήματος και την επαλήθευση των αποτελεσμάτων, αναπτύχθηκαν και συγκρίθηκαν τρεις διαφορετικές προσεγγίσεις:

- (1) **Scripted Controller:** Ένας Rule-Based ελεγκτής, ο οποίος λαμβάνει αποφάσεις πλοήγησης και αποφυγής εμποδίων αναλύοντας απευθείας τις μετρήσεις των αισθητήρων Lidar του οχήματος.
- (2) **Simple PPO:** Μια προσέγγιση Ενισχυτικής Μάθησης η οποία βελτιστοποιεί αποκλειστικά την ανταμοιβή του στόχου, αγνοώντας τους περιορισμούς ασφαλείας (Reward-only Baseline).

- (3) **PPO-Lagrangian:** Μια ασφαλής προσέγγιση Ενισχυτικής Μάθησης η οποία χρησιμοποιεί πολλαπλασιαστές Lagrange για να εξισορροπήσει δυναμικά τη μεγιστοποίηση της ανταμοιβής με την τήρηση των περιορισμών ασφαλείας.

1.1 Εργαλεία και Βιβλιοθήκες Ανάπτυξης

Για την υλοποίηση και την πειραματική αξιολόγηση του συστήματος χρησιμοποιήθηκε ένα σύγχρονο οικοσύστημα λογισμικού, το οποίο εξασφαλίζει τη φορητότητα και την επαναληψιμότητα των πειραμάτων:

- **Python 3.11:** Η βασική γλώσσα προγραμματισμού που χρησιμοποιήθηκε.
- **Virtual Environment:** Χρησιμοποιήθηκε για την απομόνωση των εξαρτήσεων κατά την τοπική ανάπτυξη και την αποφυγή συγκρούσεων μεταξύ των εκδόσεων των πακέτων (μόνο σε αρχικά στάδια του πρότζεκτ για την εύρεση σωστής έκδοσης Python και βιβλιοθηκών).
- **Docker:** Όλη η διαδικασία εκπαίδευσης και αξιολόγησης ενσωματώθηκε σε containers, επιτρέποντας την εκτέλεση του κώδικα σε οποιοδήποτε περιβάλλον χωρίς την ύπαρξη conflicts.
- **Safety Gymnasium:** Το περιβάλλον προσομοίωσης για την υλοποίηση της εργασίας.
- **PyTorch & Stable-Baselines3 (SB3):** Η βιβλιοθήκη βαθιάς μάθησης και το framework ενισχυτικής μάθησης που χρησιμοποιήθηκαν για την εκπαίδευση των μοντέλων.
- **TensorBoard:** Εργαλείο οπτικοποίησης των μετρικών των μοντέλων.

2 Εξοικίωση με Safety Gymnasium

Το ρομπότ είναι ένα Racecar, το οποίο ελέγχεται μέσω ενός πίνακα: $u = [v, \theta]^T$, όπου v είναι η επιθυμητή ταχύτητα των πίσω τροχών και θ είναι η γωνία διεύθυνσης των μπροστινών τροχών. Η ανατροφοδότηση που λαμβάνει ο agent από το περιβάλλον σε κάθε χρονικό βήμα αποτελείται από μια εξάδα τιμών: (observation, reward, cost, terminated, truncated, info).

Ο χώρος παρατηρήσεων (το observation space) περιλαμβάνει μετρήσεις από διάφορους αισθητήρες, όπως:

- **Accelerometer, Velocimeter, Gyro, Magnetometer:** Αισθητήρες που καταγράφουν την εσωτερική κατάσταση του οχήματος.
- **Lidar Sensors (Goal, Buttons, Hazards, Gremlins):** Ψευδο-Lidar αισθητήρες 16 κατευθύνσεων (έναν αισθητήρα για κάθε αντικείμενο). Κάθε αισθητήρας επιστρέφει μια τιμή που υποδηλώνει την απόσταση του αντίστοιχου αντικειμένου σε μια συγκεκριμένη κατεύθυνση.

Για τη σταθεροποίηση και τη βελτίωση της εκπαίδευσης των νευρωνικών δικτύων, εφαρμόστηκαν κατάλληλοι μετασχηματιστές στο περιβάλλον, όπως για την κανονικοποίηση των παρατηρήσεων, την εξομάλυνση των ενεργειών του αυτοκινήτου για την αποφυγή απότομων αλλαγών πορείας, και το frame stacking για την αντίληψη της χρονικής εξέλιξης της κίνησης.

3 Δημιουργία Scripted Controller

Για τη δημιουργία ενός baseline και για την κατανόηση της δυναμικής του περιβάλλον, σχεδιάστηκε και υλοποιήθηκε ένας Scripted Controller. Η λογική του ελεγκτή βασίζεται στην ανάλυση των σημάτων Lidar και χωρίζεται στα εξής στάδια:

- (1) **Ανίχνευση Στόχου:** Ο agent εντοπίζει την κατεύθυνση του επιθυμητού κουμπιού βρίσκοντας το μέγιστο σήμα στον αισθητήρα goal_lidar.
- (2) **Διαχωρισμός Εμποδίων:** Για την αποφυγή συγκρούσεων, ο ελεγκτής συνδυάζει τις μετρήσεις των αισθητήρων hazards_lidar, gremlins_lidar και των *λανθασμένων*

κουμπιών (buttons_lidar εξαιρώντας την κατεύθυνση του τρέχοντος στόχου) σε έναν ενιαίο χάρτη εμποδίων.

- (3) **Επιλογή Κατεύθυνσης Κίνησης (Gear Selection):** Αν ο στόχος βρίσκεται πίσω από το όχημα, το όχημα κατευθύνεται προς τα πίσω, ενώ στην αντίθετη περίπτωση μπροστά.
- (4) **Αποφυγή Εμποδίων:** Η ανίχνευση εμποδίων γίνεται στις 2 κατευθύνσεις κίνησης. Αν ανιχνευθεί εμπόδιο σε απόσταση μικρότερη από ένα όριο ασφαλείας στην κατεύθυνση κίνησης, ο agent στρίβει κατάλληλα μακριά από το εμπόδιο (επιλέγοντας την πλευρά με το μικρότερο κόστος εμποδίων), ενώ παράλληλα μειώνει την ταχύτητά του.

3.1 Αποτελέσματα και Ανάλυση

Ο σχεδιασμένος Scripted Controller αξιολογήθηκε στο περιβάλλον SafetyRacecarButton2-v0 για 20 ανεξάρτητα επεισόδια για διάφορα seeds. Κάθε επεισόδιο είχε μέγιστη διάρκεια 1000 βήματα. Τα συγκεντρωτικά αποτελέσματα της αξιολόγησης παρουσιάζονται στον Πίνακα 1.

Μετρική	Τιμή / Επίδοση
Αριθμός Επεισοδίων	20
Μέση Ανταμοιβή	$+3.1368 \pm 2.5198$
Ελάχιστη / Μέγιστη Ανταμοιβή	$[+0.1886, +9.0047]$
Μέσο Κόστος	202.80 ± 251.51
Μέγιστο Κόστος Επεισοδίου	819.00
Ποσοστό Επεισοδίων με Μηδενικό Κόστος	10.0% (2/20)
Ποσοστό Ασφαλών Επεισοδίων ($Cost \leq 25.0$)	30.0% (6/20)
Combined Score ($R - 1.0 \times C$)	-199.6632

Table 1. Αποτελέσματα Αξιολόγησης του Scripted Controller (20 επεισόδια)

3.1.1 *Ανάλυση Συμπεριφοράς και Περιορισμών.* Από την ανάλυση των αποτελεσμάτων και την παρατήρηση της κίνησης του οχήματος, προκύπτουν τα ακόλουθα συμπεράσματα για τη συμπεριφορά του ελεγκτή:

- **Ικανότητα Πλοήγησης:** Ο ελεγκτής επιτυγχάνει θετική μέση ανταμοιβή (+3.1368), γεγονός που δείχνει ότι το όχημα καταφέρνει να εντοπίσει και να χτυπήσει τους επιθυμητούς στόχους.
- **Πρόβλημα Κόστους:** Το μέσο κόστος ασφαλείας είναι εξαιρετικά υψηλό (202.80). Το ποσοστό των ασφαλών επεισοδίων είναι μόλις 30.0%, ενώ σε ορισμένες περιπτώσεις, το συσσωρευμένο κόστος αγγίζει πολύ υψηλές τιμές.
- **Τοπικά Ελάχιστα:** Σε περιοχές με υψηλή πυκνότητα εμποδίων ή κοντά σε εμπόδια (gremlins/hazards), ο ελεγκτής μπορεί να παρουσιάσει ταλαντώσεις στην κατεύθυνση τιμονιού, με αποτέλεσμα να παγιδεύεται και να συγκρούεται συνεχόμενα με το ίδιο εμπόδιο.

4 Simple PPO (Reward-only Baseline)

Για μια πρώτη προσέγγιση του προβλήματος βασιστήκαμε στον αλγόριθμο **Proximal Policy Optimization (PPO)**. Ο PPO είναι ένας on-policy αλγόριθμος που λειτουργεί σε συνεχή χώρο ενεργειών και χρησιμοποιεί μια τροποποιημένη συνάρτηση στόχου με περιορισμό (clipping) για να αποτρέψει τις μεγάλες και αποσταθεροποιητικές αλλαγές στην πολιτική.

4.1 Θεωρητικό Υπόβαθρο

Ο PPO βελτιστοποιεί το policy π_θ χρησιμοποιώντας έναν surrogate στόχο που περιορίζει τον ρυθμό αλλαγής της πολιτικής εντός ενός διαστήματος γύρω από τη μονάδα. Η συνάρτηση στόχου ορίζεται ως:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (1)$$

όπου:

- $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ είναι ο λόγος πιθανοτήτων της ενέργειας a_t υπό τη νέα και την παλιά πολιτική.
- $\hat{A}_t$ είναι η εκτίμηση του πλεονεκτήματος (advantage estimator) στο βήμα t .
- ϵ είναι η παράμετρος αποκοπής (clipping parameter), η οποία συνήθως ορίζεται στο 0.2.

Ο Simple PPO χρησιμοποιείται ως **Reward-only Baseline**. Αυτό σημαίνει ότι ο πράκτορας εκπαιδεύεται μόνο για την μεγιστοποίηση του reward function (ενεργοποίηση των σωστών κουμπιών), αγνοώντας πλήρως το κόστος ασφάλειας (cost) που προκύπτει από τις συγκρούσεις με εμπόδια (hazards) ή gremlins.

4.2 Διαδικασία Εκπαίδευσης και Παράμετροι

Η εκπαίδευση του Simple PPO πραγματοποιήθηκε με χρήση της βιβλιοθήκης Stable-Baselines3 (SB3). Για τη βελτιστοποίηση της μάθησης και τη σταθεροποίηση του νευρωνικού δικτύου, εφαρμόστηκε η ακόλουθη διαδικασία:

- **Κανονικοποίηση Παρατηρήσεων (Observation Normalization):** Χρησιμοποιήθηκε ο wrapper ObsNormWrapper ο οποίος υπολογίζει online τον τρέχοντα μέσο όρο και την τυπική απόκλιση των παρατηρήσεων (μέθοδος Welford) και τις κανονικοποιεί στο διάστημα $[-10, 10]$. Αυτό αποτρέπει τον κορεσμό των ενεργοποιήσεων του δικτύου λόγω των μεγάλων διακυμάνσεων των αισθητήρων Lidar.
- **Εξομάλυνση Ενεργειών (Action Smoothing):** Εφαρμόστηκε ο wrapper ActionSmoothingWrapper με εκθετικό κινητό μέσο όρο (EMA) και συντελεστή $\alpha = 0.8$. Αυτό βοηθά στη μείωση των απότομων αλλαγών στην ταχύτητα και τη γωνία διεύθυνσης, προστατεύοντας το όχημα από ανεξέλεγκτες ολισθήσεις.
- **Αρχιτεκτονική Δικτύου:** Χρησιμοποιήθηκε μια MlpPolicy με δύο κρυφά επίπεδα των 256 νευρώνων το καθένα για την πολιτική (actor) και την αξία (critic).

Οι βασικές υπερπαραμέτροι (hyperparameters) της εκπαίδευσης παρουσιάζονται στον Πίνακα 2.

Table 2. Υπερπαράμετροι Εκπαίδευσης του Simple PPO

Υπερπαράμετρος	Τιμή
Συνολικά Βήματα Εκπαίδευσης (Total Timesteps)	3.000.000
Ρυθμός Μάθησης (Learning Rate)	3×10^{-4}
Μήκος Rollout (N Steps)	4096
Μέγεθος Replay Buffer (Buffer Size)	200.000
Μέγεθος Batch (Batch Size)	512
Αριθμός Epochs (N Epochs)	10
Συντελεστής Έκπτωσης (γ)	0.99
Παράμετρος Αποκοπής (ϵ)	0.2
Συντελεστής Εντροπίας (Entropy Coefficient)	0.02

4.3 Αποτελέσματα

Τα αποτελέσματα της αξιολόγησης του εκπαιδευμένου Simple PPO μοντέλου για 20 επεισόδια παρουσιάζονται στον Πίνακα 3.

Table 3. Αποτελέσματα Αξιολόγησης του Simple PPO Controller

Μετρική	Τιμή / Επίδοση
Αριθμός Επεισοδίων	20
Μέση Ανταμοιβή (Mean Reward)	$+2.8220 \pm 2.3994$
Ελάχιστη / Μέγιστη Ανταμοιβή	$[-0.0631, +9.5873]$
Μέσο Κόστος Ασφάλειας (Mean Cost)	170.85 ± 205.60
Μέγιστο Κόστος Επεισοδίου (Max Cost)	607.00
Ποσοστό Επεισοδίων με Μηδενικό Κόστος (Zero-Cost Rate)	15.0% (3/20)
Ποσοστό Ασφαλών Επεισοδίων ($Cost \leq 25.0$)	30.0% (6/20)
Μέσο Μήκος Επεισοδίου	1000.0 βήματα
Συνδυασμένο Σκορ ($R - 1.0 \times C$)	-168.0280

5 Safe Proximal Policy Optimization

Για την επίλυση του προβλήματος της ασφάλειας, σχεδιάστηκε και υλοποιήθηκε μια προσέγγιση **Constrained Reinforcement Learning** βασισμένη στον αλγόριθμο Proximal Policy Optimization με χρήση πολλαπλασιαστών Lagrange (**PPO-Lagrangian**).

5.1 Θεωρητικό Υπόβαθρο

Το πρόβλημα της ασφαλούς πλοήγησης μοντελοποιείται ως ένα *Περιορισμένο Μαρκοβιανό Πρόγραμμα Αποφάσεων* (Constrained Markov Decision Process - CMDP). Στόχος είναι η εύρεση μιας πολιτικής π που μεγιστοποιεί την αναμενόμενη ανταμοιβή, ενώ ταυτόχρονα διασφαλίζει ότι το αναμενόμενο κόστος ασφάλειας δεν υπερβαίνει ένα όριο C_{limit} :

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t r_t \right] \quad \text{subject to} \quad \mathbb{E} \left[\sum_{t=0}^T \gamma^t c_t \right] \leq C_{\text{limit}} \quad (2)$$

Η μέθοδος των πολλαπλασιαστών Lagrange επιτρέπει τη μετατροπή του περιορισμένου αυτού προβλήματος σε ένα ισοδύναμο μη περιορισμένο πρόβλημα βελτιστοποίησης, εισάγοντας έναν

θετικό πολλαπλασιαστική $\beta \geq 0$:

$$\max_{\pi} \min_{\beta \geq 0} \mathcal{L}(\pi, \beta) = J_R(\pi) - \beta(J_C(\pi) - C_{\text{limit}}) \quad (3)$$

όπου $J_R(\pi)$ είναι η αναμενόμενη ανταμοιβή και $J_C(\pi)$ είναι το αναμενόμενο κόστος. Η βελτιστοποίηση πραγματοποιείται σε δύο επίπεδα:

- (1) **Βελτιστοποίηση Πολιτικής (π):** Η πολιτική εκπαιδεύεται να μεγιστοποιεί τη διαμορφωμένη συνάρτηση στόχου (Lagrangian reward): $r_{\text{shaped}} = r - \beta \cdot c$. Αν ο πολλαπλασιαστής β είναι μεγάλος, ο πράκτορας τιμωρείται αυστηρά για κάθε σύγκρουση, στρέφοντας την προσοχή του στην ασφάλεια. Αν $\beta = 0$, ο πράκτορας συμπεριφέρεται όπως ένας κλασικός ελεύθερος περιορισμών πράκτορας.
- (2) **Ενημέρωση Πολλαπλασιαστή (β):** Ο πολλαπλασιαστής ενημερώνεται δυναμικά στο τέλος κάθε rollout μέσω gradient ascent:

$$\beta \leftarrow \max(0, \beta + \eta(J_C(\pi) - C_{\text{limit}})) \quad (4)$$

όπου η είναι ο ρυθμός μάθησης της παραμέτρου Lagrange (Lagrangian learning rate). Αν το μέσο κόστος του rollout υπερβαίνει το C_{limit} , το β αυξάνεται, εντείνοντας την ποινή ασφάλειας. Αν το κόστος είναι χαμηλότερο από το όριο, το β μειώνεται, επιτρέποντας στον πράκτορα να εστιάσει ξανά στη συλλογή ανταμοιβών.

5.2 Υλοποίηση και Παράμετροι Εκπαίδευσης

Η υλοποίηση βασίζεται στη βιβλιοθήκη Stable-Baselines3 με την προσθήκη custom wrappers και callbacks στο αρχείο `train_ppo_lagrangian.py`:

- **LagrangianWrapper:** Αυτός ο custom wrapper παρεμβάλλεται στο βήμα της προσομοίωσης και τροποποιεί την ανταμοιβή που επιστρέφει το περιβάλλον σε $r_{\text{shaped}} = r - \beta \cdot c$, χρησιμοποιώντας την τρέχουσα τιμή του β από τον callback.
- **SafetyToGymnasiumWrapper:** Προσαρμόζει το 6-tuple του Safety Gymnasium στο 5-tuple που αναμένει η SB3. Επιπλέον, εισάγει έναν μηχανισμό ασφαλείας: αν το συσσωρευμένο κόστος του επεισοδίου υπερβεί την τιμή 50.0, το επεισόδιο τερματίζεται πρόωρα (`terminated = True`) και επιβάλλεται μια σταθερή ποινή ανταμοιβής -5.0 , αποτρέποντας τον πράκτορα από το να συνεχίσει να συγκρούεται.
- **LagrangianCallback:** Παρακολουθεί το μέσο κόστος των επεισοδίων σε κάθε rollout και ενημερώνει δυναμικά την τιμή του β σύμφωνα με τον κανόνα ενημέρωσης, καταγράφοντας την εξέλιξή του στο TensorBoard.
- **StatsSyncEvalCallback:** Διασφαλίζει ότι οι online στατιστικές κανονικοποίησης (mean/std) του εκπαιδευόμενου wrapper μεταφέρονται αυτούσιες στο περιβάλλον αξιολόγησης (evaluation environment) κατά τη διάρκεια των ενδιάμεσων ελέγχων, ώστε να μην διαταράσσεται η συμπεριφορά του ελεγκτή.

Οι βασικές υπερπαραμέτροι εκπαίδευσης του PPO-Lagrangian παρουσιάζονται στον Πίνακα 4.

Table 4. Υπερπαράμετροι Εκπαίδευσης του PPO-Lagrangian

Υπερπαράμετρος	Τιμή
Συνολικά Βήματα Εκπαίδευσης	3.000.000
Ρυθμός Μάθησης (α)	3×10^{-4}
Μέγεθος Batch (Batch Size)	64
Μήκος Rollout (N Steps)	2048
Αριθμός Epochs (N Epochs)	10
Συντελεστής Έκπτωσης (γ)	0.99
Όριο Κόστους (C_{limit})	25.0
Ρυθμός Μάθησης Lagrange (η)	0.02
Μέγιστη Τιμή Πολλαπλασιαστή (β_{max})	10.0
Συντελεστής Εντροπίας (Entropy Coefficient)	0.0

5.3 Ανάλυση Επιμέρους Στοιχείων (Ablation Studies)

Στο πλαίσιο του σχεδιασμού του συστήματος ελέγχου, ενσωματώθηκαν κατάλληλοι μετασχηματιστές (wrappers) για τη βελτίωση της εκπαίδευσης και της σταθερότητας του πράκτορα. Συγκεκριμένα:

- **Action Smoothing (Εξομάλυνση Ενεργειών):** Όπως αναφέρθηκε στην Ενότητα 4, χρησιμοποιήθηκε για τη μείωση της ολίσθησης και τη βελτίωση της σταθερότητας του οχήματος.
- **Observation Normalization (Κανονικοποίηση Παρατηρήσεων):** Όπως περιγράφηκε στην Ενότητα 4, εφαρμόστηκε κανονικοποίηση για την αποφυγή κορεσμού των νευρώνων.
- **Frame Stacking (Στοιβάξη Πλαισίων):** Εισήχθη στοιβάξη διαδοχικών παρατηρήσεων (frame stack), η οποία επιτρέπει στον πράκτορα να αντιλαμβάνεται τη σχετική ταχύτητα και την κατεύθυνση κίνησης των δυναμικών εμποδίων (gremlins), παρέχοντας την απαραίτητη χρονική πληροφορία που απουσιάζει από μια μεμονωμένη παρατήρηση.

5.4 Αποτελέσματα

Τα αποτελέσματα της αξιολόγησης του εκπαιδευμένου PPO-Lagrangian μοντέλου για 20 επεισόδια παρουσιάζονται στον Πίνακα 5 (τα δεδομένα θα συμπληρωθούν μετά την ολοκλήρωση της εκπαίδευσης).

Table 5. Αποτελέσματα Αξιολόγησης του PPO-Lagrangian Controller

Μετρική	Τιμή / Επίδοση
Αριθμός Επεισοδίων	20
Μέση Ανταμοιβή (Mean Reward)	[Υπό Εκπαίδευση]
Ελάχιστη / Μέγιστη Ανταμοιβή	[Υπό Εκπαίδευση]
Μέσο Κόστος Ασφάλειας (Mean Cost)	[Υπό Εκπαίδευση]
Μέγιστο Κόστος Επεισοδίου (Max Cost)	[Υπό Εκπαίδευση]
Ποσοστό Επεισοδίων με Μηδενικό Κόστος	[Υπό Εκπαίδευση]
Ποσοστό Ασφαλών Επεισοδίων ($Cost \leq 25.0$)	[Υπό Εκπαίδευση]
Μέσο Μήκος Επεισοδίου	[Υπό Εκπαίδευση]
Συνδυασμένο Σκορ ($R - 1.0 \times C$)	[Υπό Εκπαίδευση]

6 Συμπεράσματα

Στο πλαίσιο της παρούσας εργασίας μελετήθηκαν και αναλύθηκαν τρεις διαφορετικοί ελεγκτές για το πρόβλημα της ασφαλούς πλοήγησης ενός Racecar στο δυναμικό περιβάλλον SafetyRacecarButton2-v0 του Safety Gymnasium.

Ο **Scripted Controller** αποτελεί μια απλή και άμεση rule-based προσέγγιση, η οποία βασίζεται αποκλειστικά σε Lidar μετρήσεις. Παρόλο που καταφέρνει να πλοηγηθεί και να ενεργοποιήσει κουμπιά (μέση ανταμοιβή +3.1368), η αντιδραστική (reactive) φύση του στερείται της ικανότητας πρόβλεψης των δυναμικών του οχήματος (αδράνεια, ταχύτητα) και των κινούμενων εμποδίων, οδηγώντας σε απαράδεκτα υψηλό μέσο κόστος (202.80) και πολύ χαμηλό ποσοστό ασφαλών επεισοδίων (30%).

Οι δύο προσεγγίσεις Ενισχυτικής Μάθησης (Reinforcement Learning) αναμένεται να προσφέρουν σημαντικές βελτιώσεις:

- Ο **Simple PPO (Reward-only Baseline)** επιτυγχάνει ικανοποιητική μέση ανταμοιβή (+2.8220), καθώς εκπαιδεύεται να βελτιστοποιεί άμεσα την τροχιά του οχήματος προς τους στόχους. Ωστόσο, επειδή αγνοεί πλήρως τους περιορισμούς ασφάλειας, παρουσιάζει εξαιρετικά υψηλό κόστος ασφάλειας (170.85), επιβεβαιώνοντας ότι η κλασική RL χωρίς περιορισμούς δεν επαρκεί για εφαρμογές όπου η ασφάλεια είναι κρίσιμη.
- Ο **PPO-Lagrangian** αποτελεί τη βέλτιστη θεωρητικά λύση, καθώς χρησιμοποιεί δυναμικούς πολλαπλασιαστές Lagrange για να εξισορροπήσει τη μάθηση. Εκπαιδεύεται να τιμωρεί τη συμπεριφορά του πράκτορα όταν το συσσωρευμένο κόστος υπερβαίνει το $C_{\text{limit}} = 25.0$. Αναμένεται να επιτύχει μια ισορροπημένη συμπεριφορά πλοήγησης, διατηρώντας το μέσο κόστος εντός των ασφαλών ορίων και ικανοποιώντας τους περιορισμούς ασφάλειας.

7 Μελλοντικές Επεκτάσεις

Ως μελλοντικές κατευθύνσεις για την περαιτέρω βελτίωση του συστήματος προτείνονται:

- (1) **Ολοκλήρωση και Σύγκριση της Εκπαίδευσης:** Η πλήρης αξιολόγηση των μοντέλων Simple PPO και PPO-Lagrangian για 3.000.000 βήματα και η ποσοτική σύγκριση των αποτελεσμάτων τους με τον Scripted Controller στον τελικό πίνακα αξιολόγησης.
- (2) **Χρήση Εναλλακτικών Αλγορίθμων Safe RL:** Δοκιμή άλλων μεθόδων Constrained RL, όπως ο Constrained Policy Optimization (CPO) ή ο PPO με PID-Lagrangian ελεγκτή, οι οποίοι προσφέρουν πιο ομαλή και σταθερή σύγκλιση της παραμέτρου Lagrange β .
- (3) **Ενσωμάτωση Recurrent Αρχιτεκτονικών:** Χρήση Recurrent Νευρωνικών Δικτύων (π.χ. LSTM/GRU) για την πολιτική, ώστε ο πράκτορας να μπορεί να επεξεργάζεται χρονικές αλληλουχίες παρατηρήσεων. Αυτό θα επιτρέψει την καλύτερη εκτίμηση της ταχύτητας των κινούμενων gremlins χωρίς την ανάγκη μεγάλου frame stacking.
- (4) **Ρύθμιση Συντελεστή Εξομάλυνσης Ενεργειών:** Πειραματισμός με διαφορετικές τιμές του α στον EMA του τιμονιού για την εύρεση της χρυσής τομής μεταξύ της ευελιξίας του οχήματος και της αποφυγής ανεξέλεγκτης ολίσθησης.